

Teoria de la Probabilitat

Continguts

| | | |
|----------|---|----------|
| 2 | Variables Aleatòries | 2 |
| 2.1 | Definició de variable aleatòria. Llei d'una v.a. | 2 |
| | Definició (Fdp) | 3 |
| 2.2 | Moments d'una v.a. Desigualtats de Markov i Chebyshev | 4 |
| | Teorema (Desigualtat de Markov) | 5 |
| | Teorema (Desigualtat de Chebyshev) | 5 |
| 2.3 | Vectors de variables aleatòries. Independència de v.a. | 6 |

2 Variables Aleatòries

2.1 Definició de variable aleatòria. Llei d'una v.a.

Sigui $(\Omega, \mathcal{A}, \beta)$ un espai de probabilitat. Volem estudiar funcions de Ω amb imatge en \mathbb{R} .

Definició 2.1.1

Una **variable aleatòria** és una funció $X: \Omega \rightarrow \mathbb{R}$ tal que per tot borelià $B \in \mathcal{B}$, $X^{-1}(B) \in \mathcal{A}$.

Per tant, una variable aleatòria és una funció mesurable entre els espais de mesura (Ω, \mathcal{A}, p) i $(\mathbb{R}, \mathcal{B}, \lambda)$.

Exemple 2.1.2

(1) Les funcions constants són variables aleatòries:

$$\begin{array}{ll} X: \Omega \rightarrow \mathbb{R} \\ \omega \mapsto c \end{array} \quad \text{Si prenem } B \in \mathcal{B}, \quad X^{-1}(B) = \begin{cases} \emptyset & \text{si } c \notin B \\ \Omega & \text{si } c \in B \end{cases}$$

(2) **Variables aleatòries indicadores:**

$$\text{Sigui } A \in \mathcal{A}, \text{ definim } \mathbb{1}_A: \Omega \rightarrow \mathbb{R} \text{ on } \mathbb{1}_A(\omega) = \begin{cases} 0 & \text{si } \omega \notin A \\ 1 & \text{si } \omega \in A \end{cases}$$

$$\text{Aleshores, } B \in \mathcal{B}, \mathbb{1}_A^{-1}(B) = \begin{cases} \emptyset & \text{si } \{0, 1\} \not\subseteq B \\ A & \text{si } 1 \in B, \quad 0 \notin B \\ \bar{A} & \text{si } 1 \notin B, \quad 0 \in B \\ \Omega & \text{si } \{0, 1\} \subseteq B \end{cases}$$

(3) Si X i Y són v.a., aleshores $X + Y$, $X \cdot Y$, $|X|$, etc. són v.a.

En general, si $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ és una funció mesurable, aleshores $g(X, Y)$ és una v.a.

Estem dient que $\forall B \in \mathcal{B}$, $\{\omega \in \Omega: X(\omega) \in B\}$ és un succés i, per tant, podem calcular $P(\{\omega \in \Omega: X(\omega) \in B\}) \equiv P(X \in B)$.

Exemple 2.1.3

$$P(X \leq 1) = P(\{\omega \in \Omega: X(\omega) \in (-\infty, 1]\})$$

Les v.a. permeten traslladar l'estructura d'espai de probabilitat de (Ω, \mathcal{A}, p) en $(\mathbb{R}, \mathcal{B})$, donant lloc a mesures que no provenen de la mesura de Lebesgue.

Definició 2.1.4

Siguin (Ω, \mathcal{A}, p) un espai de probabilitat i X una v.a.

La **mesura de probabilitat induïda** per X és una mesura de probabilitat sobre $(\mathbb{R}, \mathcal{B})$ definida per

$$\begin{aligned} p_X: \mathcal{B} &\rightarrow \mathbb{R} \\ B &\mapsto p_X = P(\{\omega \in \Omega: X(\omega) \in B\}) \end{aligned}$$

Observació 2.1.5 $(\mathbb{R}, \mathcal{B}, p_X)$ és un espai de probabilitat.

De teoria de la mesura, és equivalent veure que $[\forall B \in \mathcal{B}, \quad X^{-1}(B) \text{ és de } \mathcal{A}]$ a veure que $[l'antiimatge \text{ de qualsevol interval } \in \mathcal{A}]$.

Per tant, per saber si una funció és una v.a. només cal veure si l'antiimatge dels intervals són de \mathcal{A} .

La següent definició dóna una funció en \mathbb{R} que codifica molta informació de X :

Definició (Fdp) (2.1.6)

Donada X v.a., la **funció de distribució de probabilitat** de X és:

$$\begin{aligned} F_X: \mathbb{R} &\rightarrow [0, 1] \\ x &\mapsto P(X \leq x) \end{aligned}$$

Propietats 2.1.7

(i) Si $x_1 \leq x_2 \implies F_X(x_1) \leq F_X(x_2)$

(ii) $\lim_{x \rightarrow -\infty} F_X(x) = 0$, $\lim_{x \rightarrow +\infty} F_X(x) = 1$

(iii) $F_X(x)$ és contínua per la dreta: $\forall x, \lim_{h \rightarrow 0^+} F_X(x+h) = F_X(x)$

Observació 2.1.8

- $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$
- $P(x_1 < X \leq x_2) = P(X \leq x_2) - P(X \leq x_1) = F_X(x_2) - F_X(x_1)$

Observació 2.1.9 Les propietats (i), (ii), (iii) de $F_X(x)$ són de fet suficients.

Si una funció $F(x)$ satisfà (i), (ii), (iii), aleshores és funció de probabilitat d'una variable aleatòria.

2.2 Moments d'una v.a. Desigualtats de Markov i Chebyshev

Siguin (Ω, \mathcal{A}, p) uns espai de probabilitat i X una v.a.

Definició 2.2.1

L'esperança de X és:

$$\mathbb{E}[X] = \int_{\Omega} X dp = \int_{\mathbb{R}} x dp_X$$

Més en general, si $f: \mathbb{R} \rightarrow \mathbb{R}$ és una funció mesurable,

$$\mathbb{E}[f(x)] = \int_{\Omega} f(x) dp = \int_{\mathbb{R}} f(x) dp_X$$

Observació 2.2.2 De teoria de la mesura, cal recordar que una funció g és integrable sii $|g|$ ho és (En general, $\mathbb{E}[f(x)]$ està definida sii $\mathbb{E}[|f(x)|] < +\infty$).

Si particularitzem f :

Definició 2.2.3

$f(x) = X^r \implies \mathbb{E}[X^r]$ és el **moment r-èssim**.

Definició 2.2.4

Si $\mathbb{E}[X] = p < +\infty$, $\mathbb{E}[(X - p)^r]$ és el **moment normalitzat r-èssim**.

En particular, si $r = 2$, $\mathbb{E}[(X - p)^2] = \mathbb{V}ar[X]$ és la **variància** de X .

Definició 2.2.5

Si $f(x) = x(x-1) \dots (x-r+1) \implies \mathbb{E}[f(x)] = \mathbb{E}[(X)_r]$ és el **moment factorial r-èssim**.

Proposició 2.2.6 (Propietats de l'esperança i la variància)

- Si c és la v.a. constant, $\mathbb{E}[c] = c$ i $\mathbb{V}ar[c] = 0$
- Linealitat: si $a, b \in \mathbb{R}$ i X, Y v.a., $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$
- $A \in \mathcal{A}$, $X = \mathbb{1}_A$, $\mathbb{E}[\mathbb{1}_A] = P(A)$
- $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$
- $\mathbb{V}ar[c \cdot X] = c^2 \cdot \mathbb{V}ar[X]$
- $\mathbb{V}ar[c + X] = \mathbb{V}ar[X]$
- $\mathbb{V}ar[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$

Observació 2.2.7 Si $\mathbb{E}[|X|^p] < +\infty$, aleshores podem utilitzar tots els resultats de teoria dels espais L_p . Així doncs tenim les següents conseqüències:

- Hölder: $p, q > 0, \frac{1}{p} + \frac{1}{q} = 1, \mathbb{E}[|X|^p] < +\infty, \mathbb{E}[|Y|^q] < +\infty$
 $\implies \mathbb{E}[|XY|] \leq \mathbb{E}[|X|^p]^{\frac{1}{p}} \cdot \mathbb{E}[|Y|^q]^{\frac{1}{q}} \quad (\mathbb{E}[|XY|]^{pq} \leq \mathbb{E}[|X|^p]^q \cdot \mathbb{E}[|Y|^q]^p)$
- Cauchy-Schwartz: si $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$, aleshores $\mathbb{E}[XY]^2 \leq \mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]$
- Minkowski: si $\mathbb{E}[|X|^p], \mathbb{E}[|Y|^p] < +\infty \implies \mathbb{E}[|X + Y|^p]^{\frac{1}{p}} \leq \mathbb{E}[|X|^p]^{\frac{1}{p}} + \mathbb{E}[|Y|^p]^{\frac{1}{p}}$

Teorema (Desigualtat de Markov) (2.2.8)

Sigui X un v.a. que pren valors positius i $a > 0$. Aleshores:

$$P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

El següent resultat dóna estimacions quantitatives de quant es dispersa una v.a. en relació a la seva esperança:

Teorema (Desigualtat de Chebyshev) (2.2.9)

Sigui X una v.a. en (Ω, \mathcal{A}, p) amb $\mathbb{E}[X], \mathbb{V}ar[X] < +\infty$. Aleshores, $\forall k > 0$

$$P(|X - \mathbb{E}[X]| \geq k \cdot \mathbb{V}ar[X]^{\frac{1}{2}}) \leq \frac{1}{k^2}$$

També es pot escriure:

$$P(|X - \mathbb{E}[X]| \geq k) \leq \frac{\mathbb{V}ar[X]}{k^2}$$

2.3 Vectors de variables aleatòries. Independència de v.a.