

Teoria de la Probabilitat

Continguts

1	Espais de Probabilitat	2
1.1	Definició axiomàtica d'espai de probabilitat	2
	Teorema (Desigualtats de Bonferroni)	3
1.2	Probabilitat condicionada	4
2	Variables Aleatòries	5
2.1	Definició de variable aleatòria. Llei d'una v.a.	5
2.2	Moments d'una v.a. Desigualtats de Markov i Chebyshev	7
	Teorema (Desigualtat de Markov)	8
	Teorema (Desigualtat de Chebyshev)	8
2.3	Vectors de variables aleatòries. Independència de v.a.	8
	Teorema	10

1 Espais de Probabilitat

1.1 Definició axiomàtica d'espai de probabilitat

Definició 1.1.1

Un **espai de probabilitat** és un espai de mesura (Ω, \mathcal{A}, p) , tal que $p(\Omega) = 1$.

- Ω s'anomena **espai mostral**.
- \mathcal{A} se l'anomena **conjunt d'esdeveniments** o **successos**.
- p se l'anomena **funció de probabilitat**.

Observació 1.1.2 $\mathcal{A} \subseteq \mathcal{P}(\Omega)$ és una σ -àlgebra:

$\sigma 1)$ $\emptyset \in \mathcal{A}$

$\sigma 2)$ $A \in \mathcal{A} \iff \overline{A} \in \mathcal{A}$

$\sigma 3)$ Si $\{A_n\}_{n \geq 1}$ és una seqüència de successos en $\mathcal{A} \implies \bigcup_{n \geq 1} A_n \in \mathcal{A}$

Observació 1.1.3 Recordem que p és una mesura i, per tant:

$p 1)$ $p(\emptyset) = 0$

$p 2)$ $\forall A \in \mathcal{A}, p(A) \geq 0$

$p 3)$ Si $\{A_n\}_{n \geq 1}$ és una seqüència de successos en \mathcal{A} disjunts 2 a 2 ($A_i \cap A_j = \emptyset$ si $i \neq j$), aleshores

$$p\left(\bigcup_{n \geq 1} A_n\right) = \sum_{n \geq 1} p(A_n)$$

Vegem les primeres propietats dels espais de probabilitat:

Proposició 1.1.4

Per un espai de probabilitat (Ω, \mathcal{A}, p) es compleix que:

(i) $A \in \mathcal{A} \implies p(\overline{A}) = 1 - p(A)$

(ii) Si $A, B \in \mathcal{A}, A \subseteq B \implies p(A) \leq p(B)$

(iii) Si $A_1, \dots, A_r \in \mathcal{A}, i A_i \cap A_j \neq \emptyset (i \neq j)$, aleshores $p\left(\bigcup_{i=1}^r A_i\right) = \sum_{i=1}^r p(A_i)$

(iv) Si $A, B \in \mathcal{A}, A \subseteq B \implies p(B - A) = p(B) - p(A)$

(v) Successions monòtones:

a) Si $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots \subseteq A_i \in \mathcal{A} \implies p\left(\bigcup_{n \geq 1} A_n\right) = \lim_{n \rightarrow \infty} p(A_n)$

b) Si $A_1 \supseteq A_2 \supseteq A_3 \supseteq \dots \supseteq A_i \in \mathcal{A} \implies p\left(\bigcap_{n \geq 1} A_n\right) = \lim_{n \rightarrow \infty} p(A_n)$

Si ara tenim un espai de probabilitat (Ω, \mathcal{A}, p) , i successos A_1, A_2, \dots, A_r en general no disjunts, aleshores no és cert que $p\left(\bigcup_{i=1}^r A_i\right) = \sum_{i=1}^r p(A_i)$. En aquest cas, tenim la següent fita:

Lema 1.1.5 (Fita de la unió)

Siguin A_1, A_2, \dots, A_r successos en (Ω, \mathcal{A}, p) , aleshores

$$p\left(\bigcup_{i=1}^r A_i\right) \leq \sum_{i=1}^r p(A_i)$$

Teorema (Desigualtats de Bonferroni) (1.1.6)

Siguin A_1, \dots, A_r successos en (Ω, \mathcal{A}, p) . Denotem per $I \subseteq \{1, \dots, r\} : = [r]$,

$$A_I = \bigcap_{i \in I} A_i$$

$$S_k = \sum_{\substack{I \subseteq [r] \\ |I|=k}} p(A_I)$$

Aleshores, si:

- 1) t és parell, $p\left(\bigcup_{i=1}^r A_i\right) \geq \sum_{i=1}^t (-1)^{i+1} \cdot S_i$
- 2) t és senar, $p\left(\bigcup_{i=1}^r A_i\right) \leq \sum_{i=1}^t (-1)^{i+1} \cdot S_i$

Exemple 1.1.7

1.2 Probabilitat condicionada

Definició 1.2.1

Sigui (Ω, \mathcal{A}, p) un espai de probabilitat, i $B \in \mathcal{A}$ amb $p(B) > 0$.

Per $A \in \mathcal{A}$, la **probabilitat condicionada** de A amb B és:

$$p(A | B) = \frac{p(A \cap B)}{p(B)}$$

Observació 1.2.2 $p(A | B)$ mesura la probabilitat de que el succés A ocorri sabent que B ha succeït.

Observació 1.2.3 Si prenem

$$\begin{aligned} P_B: \mathcal{A} &\rightarrow \mathbb{R} \\ A &\mapsto P_B(A) = P(A | B) \end{aligned}$$

Aleshores P_B és una funció de probabilitat sobre Ω, \mathcal{A}

De fet, si definim $\mathcal{A}_B = \{A \cap B : A \in \mathcal{A}\}$, aleshores \mathcal{A}_B és una σ -àlgebra i P_B també defineix una probabilitat sobre (Ω, \mathcal{A}_B) .

Proposició 1.2.4

Siguin $A_1, \dots, A_r \in \mathcal{A}$, tals que $p(A_i) > 0$, $A_i \cap A_j = \emptyset$ si $i \neq j$ i $\bigcup_{i=1}^r A_i = \Omega$
($\{A_i\}_{i=1}^r$ és una partició de Ω)

(i) Teorema de la probabilitat total: $\forall A \in \mathcal{A}, p(A) = \sum_{i=1}^r p(A | A_i) \cdot p(A_i)$.

(ii) Fórmula de Bayes: si $A \in \mathcal{A}$, $p(A) > 0$,

$$p(A_j | A) = \frac{p(A | A_j) \cdot p(A_j)}{\sum_{i=1}^r p(A | A_i) \cdot p(A_i)}$$

2 Variables Aleatòries

2.1 Definició de variable aleatòria. Llei d'una v.a.

Sigui $(\Omega, \mathcal{A}, \beta)$ un espai de probabilitat. Volem estudiar funcions de Ω amb imatge en \mathbb{R} .

Definició 2.1.1

Una **variable aleatòria** és una funció $X: \Omega \rightarrow \mathbb{R}$ tal que per tot borelià $B \in \mathcal{B}$, $X^{-1}(B) \in \mathcal{A}$.

Per tant, una variable aleatòria és una funció mesurable entre els espais de mesura (Ω, \mathcal{A}, p) i $(\mathbb{R}, \mathcal{B}, \lambda)$.

Exemple 2.1.2

(1) Les funcions constants són variables aleatòries:

$$\begin{array}{ll} X: \Omega \rightarrow \mathbb{R} \\ \omega \mapsto c \end{array} \quad \text{Si prenem } B \in \mathcal{B}, \quad X^{-1}(B) = \begin{cases} \emptyset & \text{si } c \notin B \\ \Omega & \text{si } c \in B \end{cases}$$

(2) **Variables aleatòries indicadores:**

$$\text{Sigui } A \in \mathcal{A}, \text{ definim } \mathbb{1}_A: \Omega \rightarrow \mathbb{R} \text{ on } \mathbb{1}_A(\omega) = \begin{cases} 0 & \text{si } \omega \notin A \\ 1 & \text{si } \omega \in A \end{cases}$$

$$\text{Aleshores, } B \in \mathcal{B}, \mathbb{1}_A^{-1}(B) = \begin{cases} \emptyset & \text{si } \{0, 1\} \not\subseteq B \\ A & \text{si } 1 \in B, \quad 0 \notin B \\ \bar{A} & \text{si } 1 \notin B, \quad 0 \in B \\ \Omega & \text{si } \{0, 1\} \subseteq B \end{cases}$$

(3) Si X i Y són v.a., aleshores $X + Y$, $X \cdot Y$, $|X|$, etc. són v.a.

En general, si $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ és una funció mesurable, aleshores $g(X, Y)$ és una v.a.

Estem dient que $\forall B \in \mathcal{B}$, $\{\omega \in \Omega: X(\omega) \in B\}$ és un succés i, per tant, podem calcular $P(\{\omega \in \Omega: X(\omega) \in B\}) \equiv P(X \in B)$.

Exemple 2.1.3

$$P(X \leq 1) = P(\{\omega \in \Omega: X(\omega) \in (-\infty, 1]\})$$

Les v.a. permeten traslladar l'estructura d'espai de probabilitat de (Ω, \mathcal{A}, p) en $(\mathbb{R}, \mathcal{B})$, donant lloc a mesures que no provenen de la mesura de Lebesgue.

Definició 2.1.4

Siguin (Ω, \mathcal{A}, p) un espai de probabilitat i X una v.a.

La **mesura de probabilitat induïda** per X és una mesura de probabilitat sobre $(\mathbb{R}, \mathcal{B})$ definida per

$$\begin{aligned} p_X: \mathcal{B} &\rightarrow \mathbb{R} \\ B &\mapsto p_X = P(\{\omega \in \Omega: X(\omega) \in B\}) \end{aligned}$$

Observació 2.1.5 $(\mathbb{R}, \mathcal{B}, p_X)$ és un espai de probabilitat.

De teoria de la mesura, és equivalent veure que $[\forall B \in \mathcal{B}, \quad X^{-1}(B) \text{ és de } \mathcal{A}]$ a veure que *[l'antiimatge de qualsevol interval $\in \mathcal{A}$].*

Per tant, per saber si una funció és una v.a. només cal veure si l'antiimatge dels intervals són de \mathcal{A} .

La següent definició dóna una funció en \mathbb{R} que codifica molta informació de X :

Definició 2.1.6

Donada X v.a., la **funció de distribució de probabilitat** de X és:

$$\begin{aligned} F_X: \mathbb{R} &\rightarrow [0, 1] \\ x &\mapsto P(X \leq x) \end{aligned}$$

Propietats 2.1.7

(i) Si $x_1 \leq x_2 \implies F_X(x_1) \leq F_X(x_2)$

(ii) $\lim_{x \rightarrow -\infty} F_X(x) = 0$, $\lim_{x \rightarrow +\infty} F_X(x) = 1$

(iii) $F_X(x)$ és contínua per la dreta: $\forall x, \lim_{h \rightarrow 0^+} F_X(x+h) = F_X(x)$

Observació 2.1.8

- $P(X > x) = 1 - P(X \leq x) = 1 - F_X(x)$
- $P(x_1 < X \leq x_2) = P(X \leq x_2) - P(X \leq x_1) = F_X(x_2) - F_X(x_1)$

Observació 2.1.9 Les propietats (i), (ii), (iii) de $F_X(x)$ són de fet suficients.

Si una funció $F(x)$ satisfà (i), (ii), (iii), aleshores és funció de probabilitat d'una variable aleatòria.

2.2 Moments d'una v.a. Desigualtats de Markov i Chebyshev

Siguin (Ω, \mathcal{A}, p) uns espai de probabilitat i X una v.a.

Definició 2.2.1

L'esperança de X és:

$$\mathbb{E}[X] = \int_{\Omega} X dp = \int_{\mathbb{R}} x dp_X$$

Més en general, si $f: \mathbb{R} \rightarrow \mathbb{R}$ és una funció mesurable,

$$\mathbb{E}[f(x)] = \int_{\Omega} f(x) dp = \int_{\mathbb{R}} f(x) dp_X$$

Observació 2.2.2 De teoria de la mesura, cal recordar que una funció g és integrable sii $|g|$ ho és (En general, $\mathbb{E}[f(x)]$ està definida sii $\mathbb{E}[|f(x)|] < +\infty$).

Si particularitzem f :

Definició 2.2.3

$f(x) = X^r \implies \mathbb{E}[X^r]$ és el **moment r-èssim**.

Definició 2.2.4

Si $\mathbb{E}[X] = p < +\infty$, $\mathbb{E}[(X - p)^r]$ és el **moment normalitzat r-èssim**.

En particular, si $r = 2$, $\mathbb{E}[(X - p)^2] = \mathbb{V}ar[X]$ és la **variància** de X .

Definició 2.2.5

Si $f(x) = x(x-1)\dots(x-r+1) \implies \mathbb{E}[f(x)] = \mathbb{E}[(X)_r]$ és el **moment factorial r-èssim**.

Proposició 2.2.6 (Propietats de l'esperança i la variància)

- Si c és la v.a. constant, $\mathbb{E}[c] = c$ i $\mathbb{V}ar[c] = 0$
- Linealitat: si $a, b \in \mathbb{R}$ i X, Y v.a., $\mathbb{E}[aX + bY] = a\mathbb{E}[X] + b\mathbb{E}[Y]$
- $A \in \mathcal{A}$, $X = \mathbb{1}_A$, $\mathbb{E}[\mathbb{1}_A] = P(A)$
- $|\mathbb{E}[X]| \leq \mathbb{E}[|X|]$
- $\mathbb{V}ar[c \cdot X] = c^2 \cdot \mathbb{V}ar[X]$
- $\mathbb{V}ar[c + X] = \mathbb{V}ar[X]$
- $\mathbb{V}ar[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$

Observació 2.2.7 Si $\mathbb{E}[|X|^p] < +\infty$, aleshores podem utilitzar tots els resultats de teoria dels espais L_p . Així doncs tenim les següents conseqüències:

- Hölder: $p, q > 0, \frac{1}{p} + \frac{1}{q} = 1, \mathbb{E}[|X|^p] < +\infty, \mathbb{E}[|Y|^q] < +\infty$
 $\implies \mathbb{E}[|XY|] \leq \mathbb{E}[|X|^p]^{\frac{1}{p}} \cdot \mathbb{E}[|Y|^q]^{\frac{1}{q}} \quad (\mathbb{E}[|XY|]^{pq} \leq \mathbb{E}[|X|^p]^q \cdot \mathbb{E}[|Y|^q]^p)$
- Cauchy-Schwartz: si $\mathbb{E}[X^2], \mathbb{E}[Y^2] < +\infty$, aleshores $\mathbb{E}[XY]^2 \leq \mathbb{E}[X^2] \cdot \mathbb{E}[Y^2]$
- Minkowski: si $\mathbb{E}[|X|^p], \mathbb{E}[|Y|^p] < +\infty \implies \mathbb{E}[|X + Y|^p]^{\frac{1}{p}} \leq \mathbb{E}[|X|^p]^{\frac{1}{p}} + \mathbb{E}[|Y|^p]^{\frac{1}{p}}$

Teorema (Desigualtat de Markov) (2.2.8)

Sigui X un v.a. que pren valors positius i $a > 0$. Aleshores:

$$P(X \geq a) \leq \frac{\mathbb{E}[X]}{a}$$

El següent resultat dóna estimacions quantitatives de quant es dispersa una v.a. en relació a la seva esperança:

Teorema (Desigualtat de Chebyshev) (2.2.9)

Sigui X una v.a. en (Ω, \mathcal{A}, p) amb $\mathbb{E}[X], \mathbb{V}ar[X] < +\infty$. Aleshores, $\forall k > 0$

$$P(|X - \mathbb{E}[X]| \geq k \cdot \mathbb{V}ar[X]^{\frac{1}{2}}) \leq \frac{1}{k^2}$$

També es pot escriure:

$$P(|X - \mathbb{E}[X]| \geq k) \leq \frac{\mathbb{V}ar[X]}{k^2}$$

2.3 Vectors de variables aleatòries. Independència de v.a.

Donat un espai de probabilitat (Ω, \mathcal{A}, p) considerem les v.a. X_1, \dots, X_n . Cadascuna d'elles defineix una distribució de probabilitat sobre \mathbb{R} .

Aleshores podem considerar el vector $(X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$.

Definició 2.3.1

Un vector $(X_1, \dots, X_n): \Omega \rightarrow \mathbb{R}^n$ és un **vector de variables aleatòries** (o una v.a. multi-dimensional), si per tot $B \in \mathcal{B}_n$ (Borelians en \mathbb{R}^n), $(X_1, \dots, X_n)^{-1}(B) \in \mathcal{A}$.

Com $\Pi_i: \mathbb{R}^n \rightarrow \mathbb{R}$ (projecció en la i -èssima component) és una funció mesurable, aleshores

$$\begin{aligned} \Pi_i(X_1, \dots, X_n): \Omega &\xrightarrow{(X_1, \dots, X_n)} \mathbb{R}^n \xrightarrow{\Pi_i} \mathbb{R} \\ \omega &\longmapsto (X_1, \dots, X_n)(\omega) \longmapsto X_i(\omega) \end{aligned}$$

$\equiv X_i(\omega)$ és una v.a. (en el sentit unidimensional).

De la mateixa manera que vam fer per les v.a. unidimensionals, podem considerar les antiimatges només en intervals.

Definició 2.3.2

Donat un espai de probabilitat (Ω, \mathcal{A}, p) , i un vector de v.a. $(X_1, \dots, X_n) = \vec{X}$, aleshores la **funció de distribució de probabilitat** de \vec{X} és $F_{\vec{X}}(x_1, \dots, x_n)$ definida per:

$$F_{\vec{X}}: \mathbb{R}^n \rightarrow [0, 1] \subseteq \mathbb{R}$$

$$(x_1, \dots, x_n) \mapsto P\left((X_1 \leq x_1) \cap (X_2 \leq x_2) \cap \dots \cap (X_n \leq x_n)\right) = P\left(\bigcap_{i=1}^n X_i \leq x_i\right)$$

Vegem propietats de la funció de distribució pel cas $n = 2$ (Per $n > 2$, és idèntic):

Lema 2.3.3

(i) Si $x'_1 \geq x_1, x'_2 \geq x_2 \implies F_{\vec{X}}(x'_1, x'_2) \geq F_{\vec{X}}(x_1, x_2)$

(ii) $\lim_{(x_1, x_2) \rightarrow (+\infty, +\infty)} F_{\vec{X}}(x_1, x_2) = 1 \quad \lim_{(x_1, x_2) \rightarrow (-\infty, -\infty)} F_{\vec{X}}(x_1, x_2) = 0$

(iii) $\lim_{(h_1, h_2) \rightarrow (0^+, 0^+)} F_{\vec{X}}(x_1 + h_1, x_2 + h_2) = F_{\vec{X}}(x_1, x_2)$ (contínua "per dalt")

Observació 2.3.4 Aquestes 3 condicions són necessàries i suficients per a definir una v.a. multidimensional.

Observació 2.3.5

- Si tenim $F_{\vec{X}}(x_1, x_2)$ associada a $\vec{X} = (X_1, X_2)$, aleshores

$$\lim_{x_2 \rightarrow +\infty} F_{\vec{X}}(x_1, x_2) = \lim_{x_2 \rightarrow +\infty} P\left((X_1 \leq x_1) \cap (X_2 \leq x_2)\right) = P(X_1 \leq x_1) = F_{\vec{X}}(x_1)$$

A aquesta funció $\left(\lim_{x_1 \rightarrow +\infty} F_{\vec{X}}(x_1, x_2)\right)$ se l'anomena **funció de distribució marginal**.

- Prenem un rectangle en \mathbb{R}^2 i $\vec{X} = (X, Y)$ v.a. multidimensional:

$$P(a < X \leq b, c < Y \leq d) = F_{\vec{X}}(b, d) - F_{\vec{X}}(a, d) - F_{\vec{X}}(b, c) + F_{\vec{X}}(a, c)$$

Definició 2.3.6

Sigui (Ω, \mathcal{A}, p) un espai de probabilitat i $\{x_i\}_{i \in I}$ un conjunt de v.a. Direm que $\{x_i\}_{i \in I}$ són **independents** si: $\forall k, \forall i_1, \dots, i_k \subseteq I, \forall B_1, \dots, B_k \in \mathcal{B}$

$$P(X_{i_1} \in B_1, X_{i_2} \in B_2, \dots, X_{i_k} \in B_k) = \prod_{j=1}^k P(X_{i_j} \in B_j)$$

Si ara prenem X_1, \dots, X_k v.a., aleshores si són independents,

$$F_{X_1, \dots, X_k}(x_1, \dots, x_k) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_k \leq x_k) = \prod_{j=1}^k P(X_j \leq x_j) = \prod_{j=1}^k F_{X_j}(x_j)$$

Observació 2.3.7 Si X i Y són v.a. independents i f, g funcions mesurables, aleshores $f(X)$ i $g(Y)$ són també independents.

Observació 2.3.8 Si $F_{X_1, \dots, X_k}(x_1, \dots, x_k) = \prod_{j=1}^k F_{X_j}(x_j)$, aleshores les v.a. X_1, \dots, X_k són independents.

En quant al càlcul de moments, tenim el següent resultat:

Teorema (2.3.9)

Siguin X_1, \dots, X_k v.a. independents. Aleshores, si $\mathbb{E}[X_i] < +\infty$, es compleix que

$$\mathbb{E}\left[\prod_{i=1}^k X_i\right] = \prod_{i=1}^k \mathbb{E}[X_i]$$

Vam veure que l'operador esperança és lineal, però això no és cert en general per la variància. De fet, en el segon cas obtenim un terme connector anomenat covariància.

Definició 2.3.10

Donades dues v.a. X, Y , la **covariància** de X i Y ($Cov(X, Y)$) és:

$$Cov(X, Y) = \mathbb{E}\left[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])\right]$$

Si ara desenvolupem aquesta expressió, obtenim: $Cov(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.

Observem que si X i Y són independents, aleshores $X - \mathbb{E}[X]$ i $Y - \mathbb{E}[Y]$ també ho són i, per tant:

$$Cov(X, Y) = \mathbb{E}\left[(X - \mathbb{E}[X]) \cdot (Y - \mathbb{E}[Y])\right] = \mathbb{E}\left[X - \mathbb{E}[X]\right] \cdot \mathbb{E}\left[Y - \mathbb{E}[Y]\right] = (\mathbb{E}[X] - \mathbb{E}[X]) \cdot (\mathbb{E}[Y] - \mathbb{E}[Y]) = 0$$

Observació 2.3.11 $Cov(X, Y) = 0 \not\Rightarrow X$ i Y independents.

Si ara calculem la variància d'una suma, obtenim:

$$\mathbb{V}ar[X + Y] = \mathbb{V}ar[X] + \mathbb{V}ar[Y] + 2 \cdot Cov(X, Y)$$

Observació 2.3.12 Si X i Y són independents, $Cov(X, Y) = 0$ i per tant, $\mathbb{V}ar[X + Y] = \mathbb{V}ar[X] + \mathbb{V}ar[Y]$.

En general, això és cert per n v.a. independents:

$$\mathbb{V}ar\left[\sum_{i=1}^n X_i\right] = \sum_{i=1}^n \mathbb{V}ar[X_i] \quad \text{si } \{X_i\}_{i=1}^n \text{ són independents.}$$

Vegem ara propietats de la covariància:

Propietats 2.3.13

- (i) $Cov(c, X) = 0$ (c és una constant)
- (ii) Si c és una constant, $Cov(c + X, Y) = Cov(X, Y)$
- (iii) $Cov(X, X) = Var[X]$
- (iv) $Cov(X, Y) = Cov(Y, X)$
- (v) $Cov(aX + bY, Z) = a \cdot Cov(X, Z) + b \cdot Cov(Y, Z)$

Definició 2.3.14

Anomenem **coeficient de correlació de Pearson** ($\rho(X, Y)$) a:

$$\rho(X, Y) = \frac{Cov(X, Y)}{Var[X]^{\frac{1}{2}} \cdot Var[Y]^{\frac{1}{2}}} \in [-1, 1]$$

Observació 2.3.15

Sabem que la igualtat en *Cauchy-Schwartz* es dona quan $\exists a$ tal que $a \cdot X = Y$.
A més, $Cov(aX + b, Y) = Cov(aX, Y)$. Per tant,

$$Y = aX + b \iff \rho(X, Y) \in \{\pm 1\}$$

Així doncs, com més proper sigui $\rho(X, Y)$ a ± 1 , millor serà una aproximació lineal de Y usant X .